Shenzhen The Nine’s Light Technology Co., Ltd.

Q-Agent-AI 数智人一体机

技术规格及性能指标参考

2025-12

九章之光

The Nine’s Light to AGI

Q-Agent-AI 数智人一体机（户外版）
技术规格及性能指标参考

类别	描述
产品定位	一个集成感知、理解、生成、交互于一体的 全模态 **AI Agent** 实时数智人交互系统
产品亮点	亮点 1：**“实时”和“端到端”的集成**
	亮点 2：**系统持续学习、自我修正、动态更新**
全模态实时异构计算集群	**Q-Agent** 不是一个模型，是由 **5** 种核心模态、数十个模型和子系统构成的**“实时异构计算集群”** 即 **Transformer + Clip + 空间计算** 包含模态： ● **文本模态 (Text/Language Modality)** 输入：用户文本对话、ASR 转录文本、知识库文档 输出：LLM 回复、系统指令、RAG 检索结果 核心技术：LLM 大模型集群 Graph RAG、Knowledge Graph 数据形式：符号序列(tokens) 时序特征：强序列依赖 ● **音频 (Audio Modality)** 输入：麦克风、ASR 输出：TTS、超拟人情感语音、定制方言语音 核心技术： wav2vec2+分类头、ITN 逆文本正则化、TN 文本正则化、声源定位 数据形式：波形序列、频谱图 时序特征：强时序性 ● **视觉 (Visual Modality)** 输入：4K 相机、人脸、物体检测、视频流 输出：拍照、图像生成、场景理解 核心技术：VLM、YOLO、视觉向量 数据形式：2D 像素矩阵序列 时序特征：视频有时序性，单帧图像无 ● **深度/空间 (Depth/Spatial Modality)** 输入：RealSense 深度相机、点云数据 输出：空间定位反馈、空间关系 核心技术：Open3D, 3D 处理 数据形式：3D 坐标+深度值 时序特征：可以是静态或动态 ● **动作/姿态 (Motion/Gesture Modality)**

	输入：姿态识别、手势识别、表情变化（面部动作单元） 输出：数智人交互动作驱动 核心技术：MediaPipe，动作库 数据形式：关键点轨迹、动作序列 时序特征：强时序性
设备架构	**云边端一体化协同：** ● **云端**：GPU 推理+API 调用+庞大的微服务调用 ● **边缘计算设备**：**模多多 AI 算力塔（自研）** ● **端侧设备：模多多I代多传感器总成（自研）** 含 4K 高清摄像头、深度传感器、RGB 传感器 ACE+波束成形麦克风阵列、FPGA 集成版 ● **展示设备：**LCD 显示屏、定向声学声频播放、**模多多 AI 一体机集成仓体（自研）**
引擎层	
多模态时空对齐引擎	● **时间同步**：统一时间戳，对齐各传感器数据 **PTP 精准时间协议+硬件时间戳** ● **空间对齐**：统一坐标系，关联视觉/深度/语音 **相机标定+坐标系统一（世界坐标系）** ● **身份关联**：通过人脸和声纹确定"谁在说话、谁在移动"
场景理解统一表示	"timestamp": 1703232000.123, "persons": [{id, bbox, position_3d, is_speaking, speech, face}], "objects": [{id, bbox, class, confidence, position_3d}], "scene_description": "...", "events": ["person_approaching", "speech_detected"]
视觉感知处理引擎	双层视觉架构，含视觉语义检索
空间感知处理引擎	VLM+点云处理+空间计算
多模态感知及意图识别	多模态对齐+多模态意图识别
多智能体框架引擎	Moduoduo Agent Flow（moduoduo.site）
模型及智能体系统记忆引擎	Moduoduo Memory，记忆继承、沙箱隔离
核心安全及可控解决路径	
降级部署	解决断网情况下设备功能持续运行的问题 L1 降级：云端不可用→边缘模型接管 L2 降级：实时推理失败→响应缓存库 恢复策略：自动健康检查+热切换
实时性：流水线延迟累积	全流水线任务并行化处理，关键路径使用缓存和预计算，设置超时熔断机制
稳定性：数十个模型同时运行	大模多多-起底-N 个微服务架构解耦，稳定的消息队列

多模态对齐	时间同步协议和缓存队列管理
计算性能及性价比	边缘计算+云弹性扩容，模型加载策略，常驻内存管理
幻觉及错误传播	关键决策多通道验证机制（确定性检测、多模型投票、敏感操作用户确认机制）、双层安全过滤
消息流	
通信协议	gRPC + Protobuf（低延迟 RPC）+ WebSocket（实时流）
消息队列	Redis Streams（实时） + RabbitMQ（任务队列）
动态更新指标	
基础模型及 **AI** 能力动态更新	48 小时（国内）/96 小时（全球）完成最新模型更换
实时性指标	
文本对话端到端交互	<500ms（LLM + RAG）
语音交互端到端延迟	交付值 3-4 秒，实际目前首音返回＜2 秒
实时视觉识别互动	<300ms（YOLO + VLM 双层架构）
实时图像生成	交付值<5s（文生图/图生图）
AI 智能拍照	交付值<5s（摄像头 + 人脸识别 + 创意合成）
视觉检测延迟	YOLO 实时检测：<30ms（单帧） VLM 深度理解：<800ms（按需调用） 双层架构总延迟：<300ms（优化流水线）
数字人实时驱动渲染	30-60 FPS
主动打招呼响应	<2 秒（从检测到开始说话）
3D 深度感知	<300ms（RealSense + 点云处理）
多模态并行延迟优化策略	ASR →LLM→TTS→渲染 ｜ 串行：1500ms
流式并行优化策略	VLM →LLM→TTS→并行+流式：800ms
准确性指标	
语音识别准确率	>95%（中文普通话）
人脸识别准确率	>98%
知识问答准确率	>90%（知识库内）
意图识别准确率	>85%
稳定性指标	
系统可用性	>99%（7×24 小时）
平均无故障时间	>720 小时（30 天）
故障恢复时间	<3 分钟（自动重启）

模型优化	
TensorRT 量化	FP16→INT8
超时熔断	if latency > 1000ms
视觉幻觉控制机制	交叉验证+置信度检查
硬件加速	TensorRT 引擎预编译、CUDA Graph 优化